Санкт-Петербургский Политехнический
университет имени Петра Великого

Отчёт по лабораторной работе №3

Боксплот Тьюки и анализ выбросов

Студент: Аюшева Рената Рафаэльевна
Группа: 5030102/30202

Санкт-Петербург
2026

1 Постановка задачи

В рамках данной лабораторной работы было необходимо:

- Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений.
- Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значе- ний.

2 Теоретическая часть

В данной работе требовалось изучить следующие распределения случайных величин:

- Нормальное распределение $N(x; 0, 1)$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \in \mathbb{R}$$

- Распределение Коши $C(x; 0, 1)$

$$f(x) = \frac{1}{\pi(1 + x^2)}, \quad x \in \mathbb{R}$$

- Распределение Лапласа $L\left(x; 0, \frac{1}{\sqrt{2}}\right)$

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in \mathbb{R}$$

- Распределение Пуассона $P(k; 5)$

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \ldots$$

- Равномерное распределение $U(x; -\sqrt{3}, \sqrt{3})$

$$f(x) = \frac{1}{2\sqrt{3}}, \quad x \in [-\sqrt{3}, \sqrt{3}]$$

Выбросами будут считаться значения, не попавшие в интервал

$$[Q_1 - IQR \cdot 1.5; Q_3 + IQR \cdot 1.5]$$

Таким образом, можно аналитически сосчитать теоретическую долю выбросов.

Распределение	**Доля выбросов**
N(0,1)	0.7%
C(0,1)	15.6%
L(0, $1/\sqrt{2}$)	6.25%
P(5)	1.37%
U(-$\sqrt{3}$, $\sqrt{3}$)	0%

Таблица 1: Теоретическая доля выбросов

3 Реализация

Практическая часть работы была реализована на языке программирования `Python` с использованием библиотек: `scipy,seaborn,numpy,pandas`.
Среда разработки: `PyCharm`.

Были реализованы следующие функции:

- `get_outliers_count(data)` — вычисляет количество аномальных значений в выборке по методу Тьюки. (data) - генерируемые значения
- `get_theoretical_share(dist_type, **params)` — расчет теоретической вероятности появления выброса для заданного распределения. (dist_type) - название распределения, (**params) - параметры распределения
- `boxplots_Tiuki()` — основная функция для запуска 1000 итераций.

4 Результаты

Ниже представлены боксплоты и таблица долей выбросов.

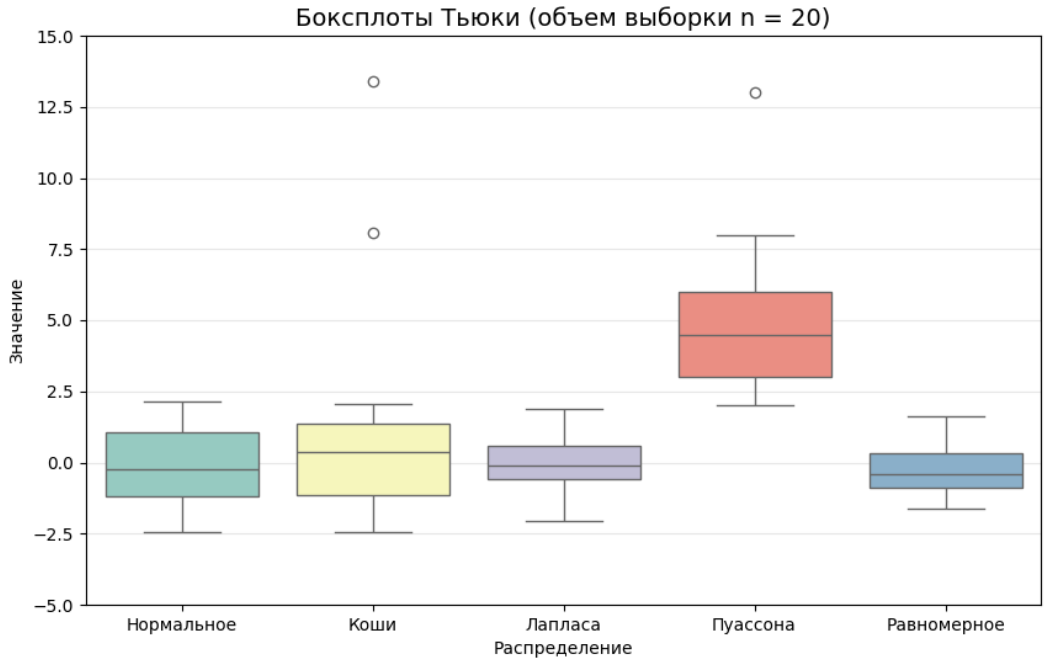

Рис. 1: Боксплоты распределений для $n = 20$

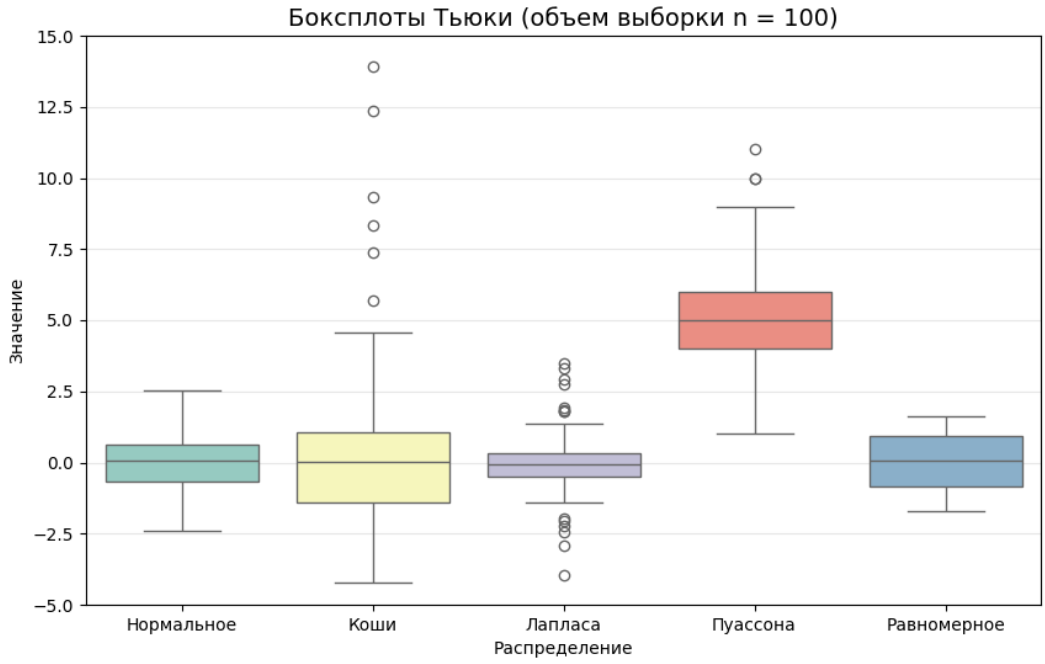

Рис. 2: Боксплоты распределений для $n = 100$

Распределение	**Средняя доля выбросов**
Нормальное	2.25%
Коши	15.14%
Лапласа	7.46%
Пуассона	2.44%
Равномерное	0.17%

Таблица 2: Средняя доля выбросов для различных распределений при $n = 20$

Распределение	**Средняя доля выбросов**
Нормальное	1.01%
Коши	15.69%
Лапласа	6.58%
Пуассона	1.47%
Равномерное	0.00%

Таблица 3: Средняя доля выбросов для различных распределений при $n = 100$

5 Обсуждение

Анализ полученных результатов позволяет сделать выводы о зависимости количества выбросов от природы распределения:

- **Распределение Коши** характеризуется «тяжёлыми хвостами», что обуславливает самое высокое количество выбросов (порядка 15–16%). Это подтверждает высокую вероятность появления значений, значительно удалённых от центра.
- **Нормальное распределение** имеет «лёгкие хвосты», вследствие чего доля выбросов минимальна и при росте выборки стремится к теоретическим 0.7%.
- **Распределение Лапласа** занимает промежуточное положение. Его хвосты тяжелее нормального, что отражается в средней доле выбросов около 6–7%.
- **Распределение Пуассона** является дискретным и асимметричным. При $\lambda = 5$ экстремальные значения возникают редко, и доля выбросов невелика.
- **Равномерное распределение** ограничено интервалом $[-\sqrt{3}, \sqrt{3}]$. Границы Тьюки лежат за пределами этого интервала, поэтому появление выбросов практически невозможно (0%).

Влияние объёма выборки n:

- С ростом n экспериментальная оценка доли выбросов становится более стабильной и демонстрирует явную сходимость к теоретическому значению.

- При увеличении размера выборки боксплоты становятся более информативными, а квартили Q_1 и Q_3 определяются более корректно, снижая влияние случайного шума.

6 Выводы

1. Увеличение объёма выборки сводит экспериментальную долю аномальных значений к их теоретическим вероятностям.
2. Сама доля выбросов при увеличении n не обязательно должна монотонно падать; она может колебаться, но её статистическая устойчивость существенно повышается.
3. Метод боксплота Тьюки эффективно визуализирует «тяжесть» хвостов распределений, позволяя наглядно сравнивать их склонность к генерации аномалий.

7 Список литературы

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/
2. Документация `seaborn` - https://seaborn.pydata.org/

8 Приложение

https://github.com/chumarena/MatStat/tree/main/Lab3