Санкт-Петербургский Политехнический
университет имени Петра Великого

Отчёт по лабораторной работе №4

Эмпирическая функция распределения и ядерные оценки плотности

Студент: Аюшева Рената Рафаэльевна
Группа: 5030102/30202

Санкт-Петербург
2026

1 Постановка задачи

В рамках данной лабораторной работы было необходимо:

- Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения
- Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

2 Теоретическая часть

В данной работе требовалось изучить следующие распределения случайных величин:

- Нормальное распределение $N(x; 0, 1)$

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \in \mathbb{R}$$

- Распределение Коши $C(x; 0, 1)$

$$f(x) = \frac{1}{\pi(1 + x^2)}, \quad x \in \mathbb{R}$$

- Распределение Лапласа $L\left(x; 0, \frac{1}{\sqrt{2}}\right)$

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in \mathbb{R}$$

- Распределение Пуассона $P(k; 5)$

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \ldots$$

- Равномерное распределение $U(x; -\sqrt{3}, \sqrt{3})$

$$f(x) = \frac{1}{2\sqrt{3}}, \quad x \in [-\sqrt{3}, \sqrt{3}]$$

Эмпирическая функция распределения определяется как:

$$F^*(x) = \frac{n_x}{n}, (n_x = |\{x_i | x_i < x\}|)$$

Ядерная оценка плотности распределения определяется как:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

В рамках данной лабораторной работы:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}$$

Правило Скотта (для одномерного случая):

$$h = \sigma \cdot n^{-\frac{1}{4}}$$

3 Реализация

Практическая часть работы была реализована на языке программирования `Python` с использованием библиотек: `scipy,seaborn,numpy`.
Среда разработки `PyCharm`

Были реализованы следующие функции:
`get_distributions()` — функция, инициализирующая словарь исследуемых распределений.
`plot_dist(dist, x_lim, title, is_cdf=True)` — универсальная функция визуализации, реализующая построение графиков для выборок трёх разных объёмов ($n = 20, 60, 100$). В зависимости от флага `is_cdf` выполняет одну из следующих задач:

- При `is_cdf=True`: отображает теоретическую функцию распределения и эмпирическую функцию распределения (ЭФР). Реализована экстраполяция данных до границ осей для исключения визуальных разрывов.
- При `is_cdf=False`: отображает теоретическую плотность (или функцию массы для дискретных величин) и её приближение, полученное методом ядерного сглаживания (KDE).

`dist` - объект распределения. `x_lim` - границы. `title` - название распределения.

4 Результаты

Ниже представлены графики приближений (синие), их теоретические кривые (красные).

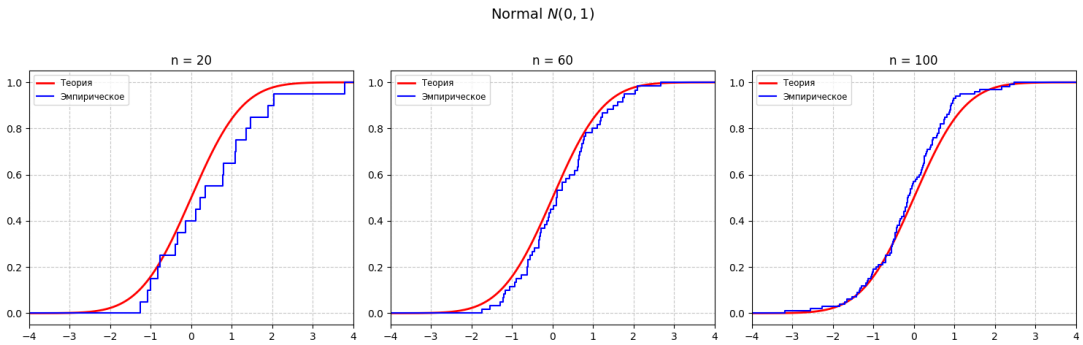

Рис. 1: Приближение эмпирической функцией N

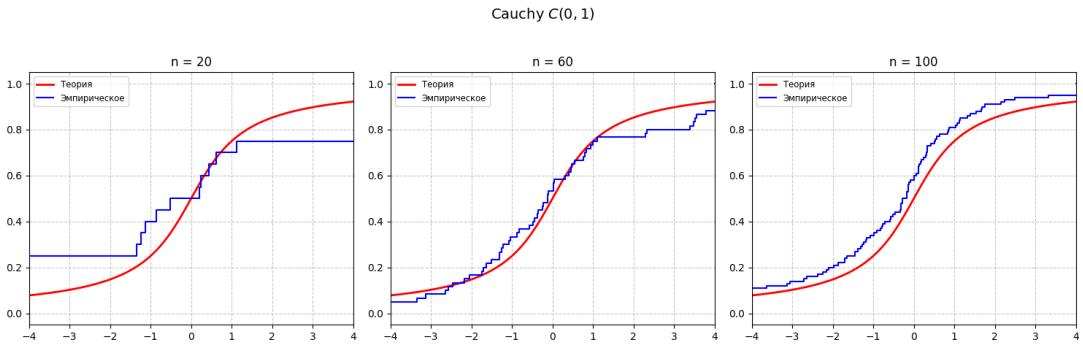

Рис. 2: Приближение эмпирической функцией C

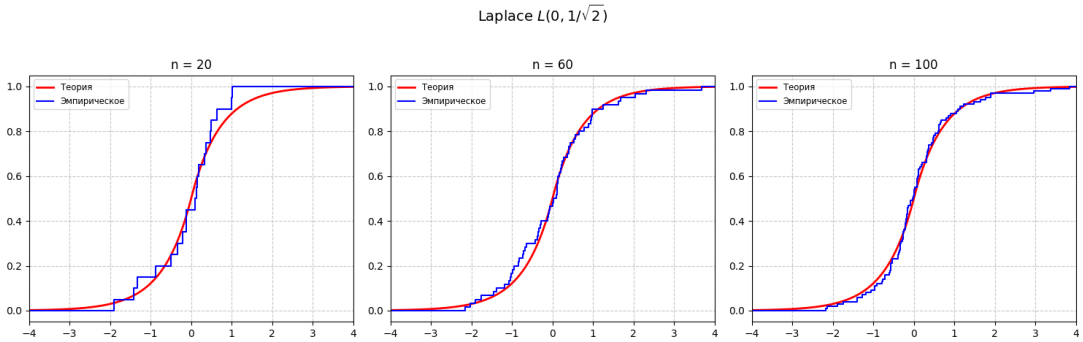

Рис. 3: Приближение эмпирической функцией L

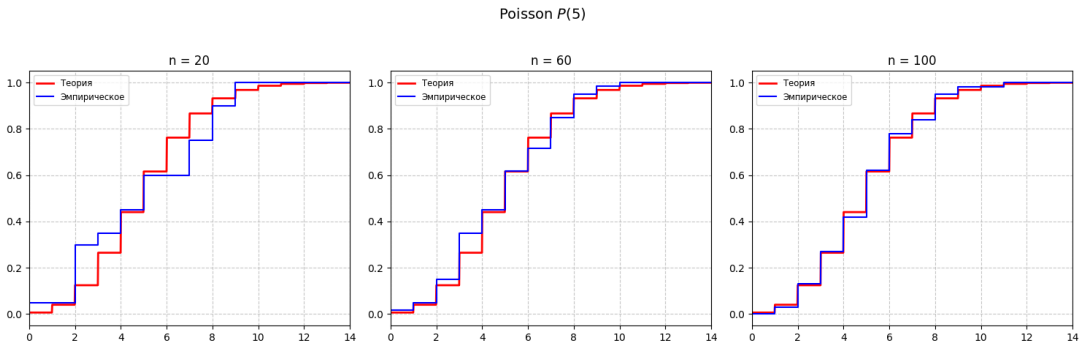

Рис. 4: Приближение эмпирической функцией P

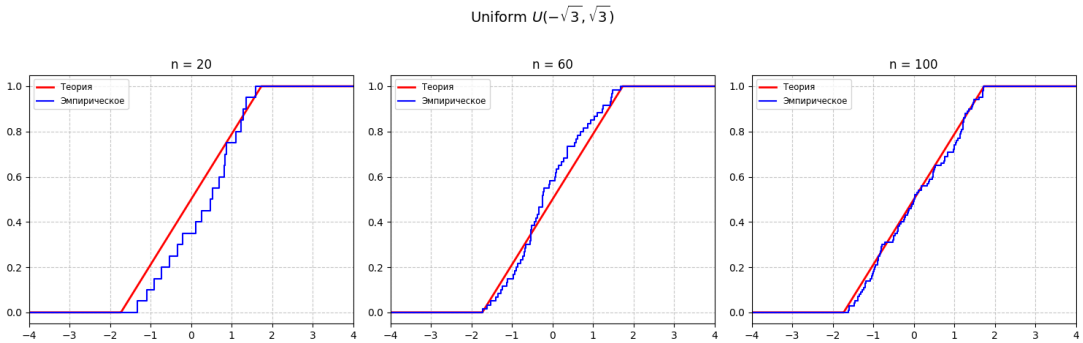

Рис. 5: Приближение эмпирической функцией U

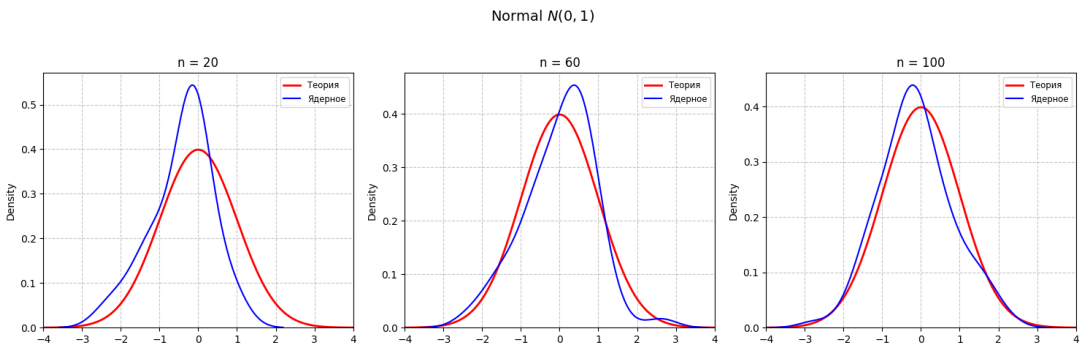

Рис. 6: Приближение ядерным сглаживанием N

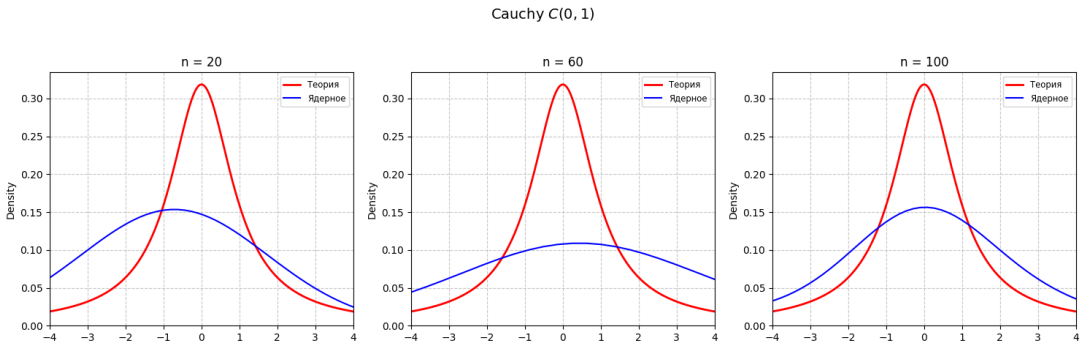

Рис. 7: Приближение ядерным сглаживанием C

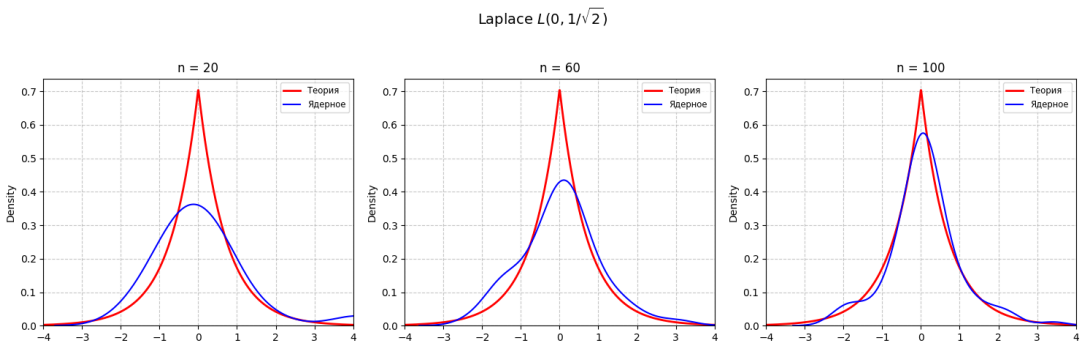

Рис. 8: Приближение ядерным сглаживанием L

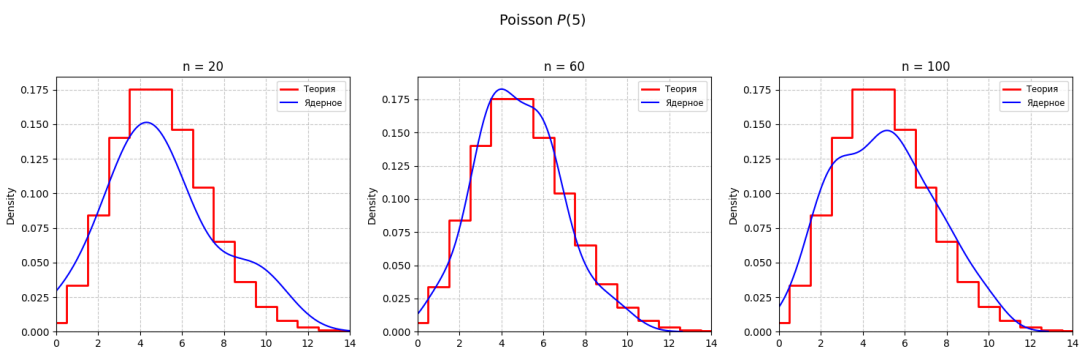

Рис. 9: Приближение ядерным сглаживанием P

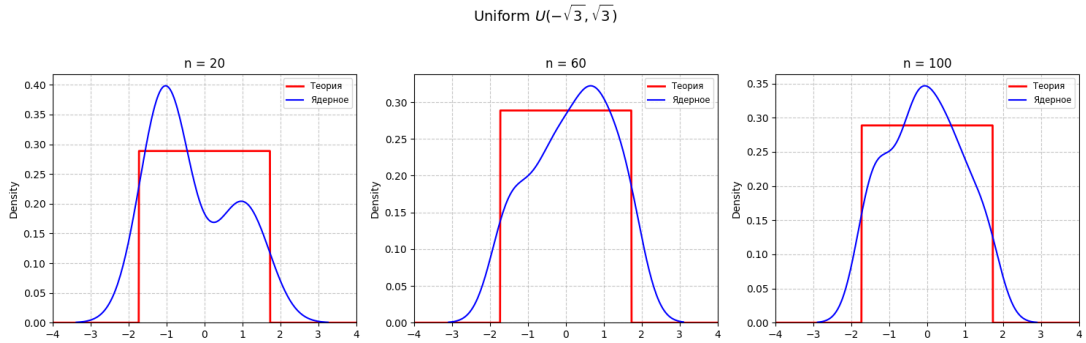

Рис. 10: Приближение ядерным сглаживанием U

5 Обсуждение

Из представленных выше графиков видно, что значения эмпирических функций с увеличением размера выборки становятся ближе к истинным значениям функций распределений (т Гливенко–Кантелли)

Преимущество приближения ядерными функциям плотностей вероятностей заключается в их гладкости, а также не нужно настраивать число/ширину бинов.(в сравнении с гистограммами)

Тем не менее, у ядерных оценок есть свои недостатки, которых нет у гистограмм:

- Плохая интерпретируемость.
- Более затратны с вычислительной точки зрения.

Во время исследования полученных графиков для распределения Коши, я заметила, что ядерное приближение получается пологим(в частности из-за тяжелых хвостов). Отсюда можно сделать следующий вывод:
От значения параметра h принципиально зависит качество приближения. Если h будет мало, то график будет выглядеть как сильно осциллирующая линия. Если же наоборот - установить данный параметр слишком большим, то график будет пологим, и он так же будет являться плохим приближением.

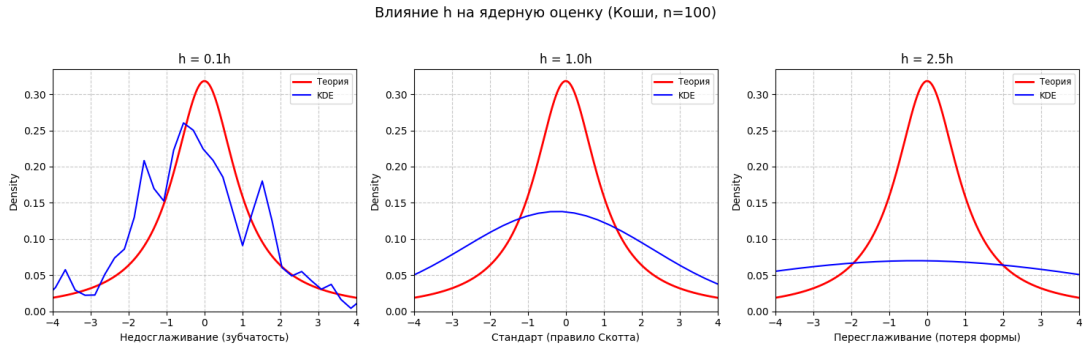

Рис. 11: Приближение ядерным сглаживанием N для h равным 2.5h, 1h, 0.1h

6 Выводы

1. Эмпирическая функция распределения сходится к соответствующей теоретической, что и согласуется с теоремой Гливенко–Кантелли.

2. Ядерные оценки плотности обладают преимуществом над гистограммами: они являются гладкими, при этом не требуют подбора количества границ и интервалов. В отличие от ступенчатой гистограммы, ядерное сглаживание даёт более реалистичное представление о форме распределения.

3. Выбор параметра h существенно влияет на качество приближения Ядерной Оценкой.

7 Список литературы

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/

2. Документация `seaborn` - https://seaborn.pydata.org/

8 Приложение

https://github.com/chumarena/MatStat/tree/main/Lab4