Санкт-Петербургский Политехнический
университет имени Петра Великого

Отчёт по лабораторной работе №5

Корреляционный анализ и эллипсы рассеивания

Студент: Аюшева Рената Рафаэльевна
Группа: 5030102/30202

Санкт-Петербург
2026

1 Постановка задачи

В рамках данной лабораторной работы было необходимо:

- Сравнить исходное заначение коэффициента корреляции с вычисленными.
- Изучить способы визуализации ковариационной структуры данных.

2 Теоретическая часть

В данной работе требовалось изучить двумерную случайную величину, подчиняющуюся закону:

$$f(x,y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_x)^2}{\sigma_x^2} - 2\rho\frac{(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y} + \frac{(y-\mu_y)^2}{\sigma_y^2}\right]\right)$$

Выборочный коэффициент корреляции Пирсона

$$r = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2}\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-\bar{y})^2}}$$

Выборочный квадрантный коэффициент корреляции

$$r_Q = \frac{(n_1+n_3)-(n_2+n_4)}{n},$$

где n_1, n_2, n_3 и n_4 — количества точек с координатами (x_i, y_i), попавших соответственно в 1, 2, 3 и 4 квадранты декартовой системы с осями $x' = x - \operatorname{med} x$, $y' = y - \operatorname{med} y$ и с центром в точке с координатами $(\operatorname{med} x, \operatorname{med} y)$.

Выборочный коэффициент ранговой корреляции Спирмена определяется как выборочный коэффициент корреляции Пирсона между рангами u_i и v_i переменных X и Y:

$$r_S = \frac{\frac{1}{n}\sum_{i=1}^{n}(u_i-\bar{u})(v_i-\bar{v})}{\sqrt{\frac{1}{n}\sum_{i=1}^{n}(u_i-\bar{u})^2 \cdot \frac{1}{n}\sum_{i=1}^{n}(v_i-\bar{v})^2}},$$

где $\bar{u} = \bar{v} = \dfrac{1+2+\cdots+n}{n} = \dfrac{n+1}{2}$ — среднее значение рангов.

Ранжирование происходит следующим образом - данные из выборки упорядочиваются в порядке возрастания, и затем им присваиваются номера, которые и являются рангами.

Для построения эллипса равновероятностей необходим задать центр, угол наклона, ширину и высоту.

1. В качестве центра берётся точка (EX, EY)
2. Угол наклона определяется из равенства:

$$tg2\alpha = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 - \sigma_y^2}$$

3. В качестве ширины и высоты эллипса берутся собственные числа ковариационной матрицы, умноженные на некоторую постоянную $const$.

3 Реализация

Практическая часть работы была реализована на языке программирования `Python` с использованием библиотек: `scipy,seaborn,numpy,pandas, matplotlib`. Среда разработки `PyCharm`.

Были реализованы следующие функции:

`calculate_quadrant(x, y)` — функция, вычисляющая выборочный квадрантный коэффициент корреляции.
`get_all_correlations(x, y)` - функция, которая считает коэффициенты Пирсона, Спирмена и квадрантный
`generate_tables(n_sizes, rho_values, iterations=1000)` - функция, которая генерирует и выводит статистические таблицы для разных n
`plot_ellipses(n_sizes, rho_values, n_std=2.0)` - функция , которая строит диаграммы рассеивания с эллипсами для каждого случая

4 Результаты

```
============================= Таблица для n = 20 =============================
      p  Pearson μ  Pearson σ²  Spearman μ  Spearman σ²  Quadrant μ  Quadrant σ²
    ρ=0  -0.005149    0.053714   -0.002179     0.053549   -0.001800     0.051957
  ρ=0.5   0.482684    0.032668    0.454176     0.035094    0.318200     0.044629
  ρ=0.9   0.896748    0.002424    0.867591     0.004162    0.695600     0.027981
mixture   0.433853    0.137215    0.666423     0.026595    0.600600     0.029720

============================= Таблица для n = 60 =============================
      p  Pearson μ  Pearson σ²  Spearman μ  Spearman σ²  Quadrant μ  Quadrant σ²
    ρ=0   0.004405    0.016749    0.006741     0.016767    0.002133     0.016991
  ρ=0.5   0.500140    0.010075    0.480715     0.011090    0.338933     0.014715
  ρ=0.9   0.898371    0.000686    0.882796     0.001088    0.705533     0.008485
mixture   0.411759    0.057595    0.690641     0.008845    0.626267     0.008892

============================= Таблица для n = 100 =============================
      p  Pearson μ  Pearson σ²  Spearman μ  Spearman σ²  Quadrant μ  Quadrant σ²
    ρ=0   0.003476    0.010099    0.003547     0.010352    0.001800     0.010446
  ρ=0.5   0.493643    0.006004    0.475154     0.006724    0.333160     0.009262
  ρ=0.9   0.898819    0.000371    0.885826     0.000583    0.707520     0.004830
mixture   0.392189    0.034166    0.690802     0.004876    0.631480     0.005497
```

Рис. 1: Результаты вычислений коэффициентов корреляций

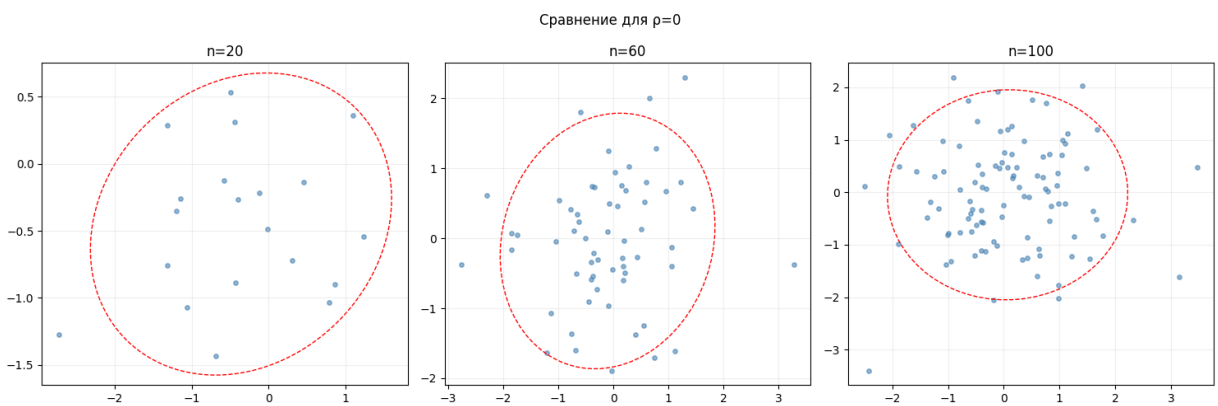

Рис. 2: Диаграммы рассеиваний и эллипсы равновероятностей при $\rho = 0$

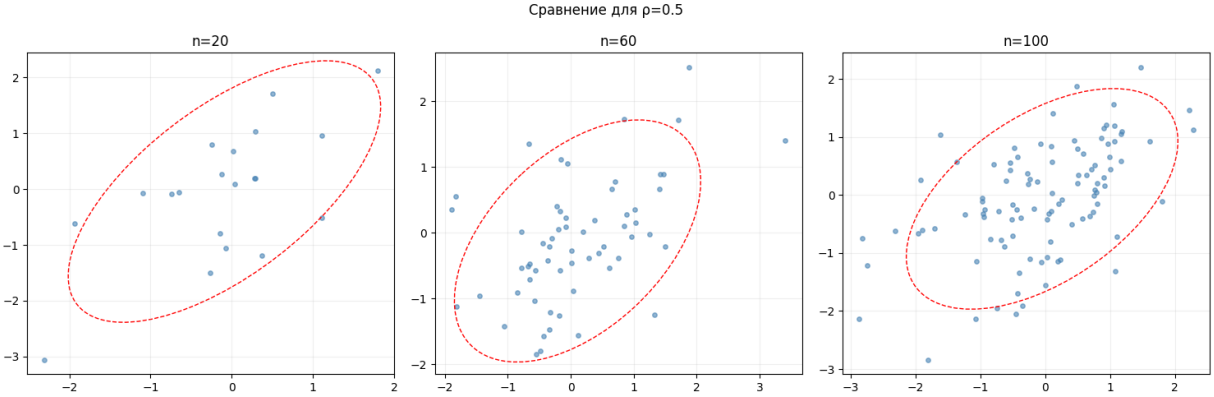

Рис. 3: Диаграммы рассеиваний и эллипсы равновероятностей при p = 0.5

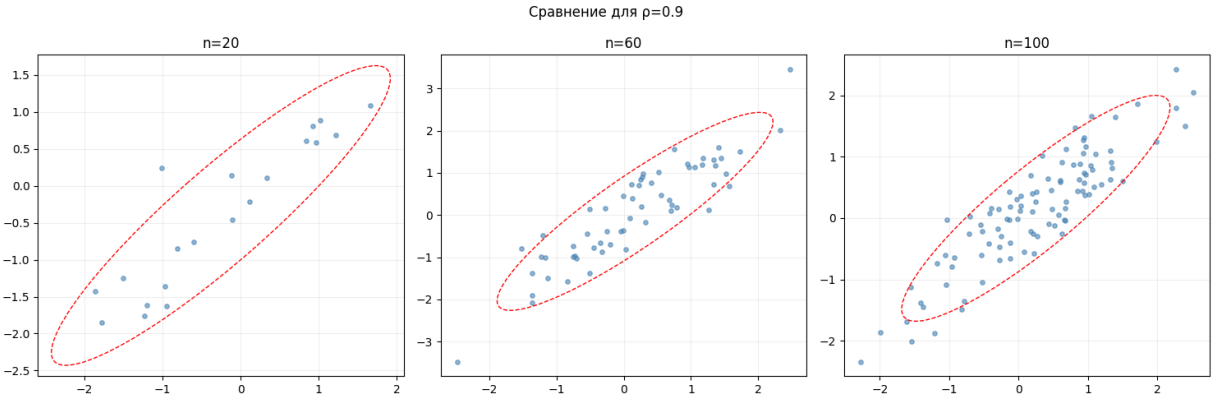

Рис. 4: Диаграммы рассеиваний и эллипсы равновероятностей при p = 0.9

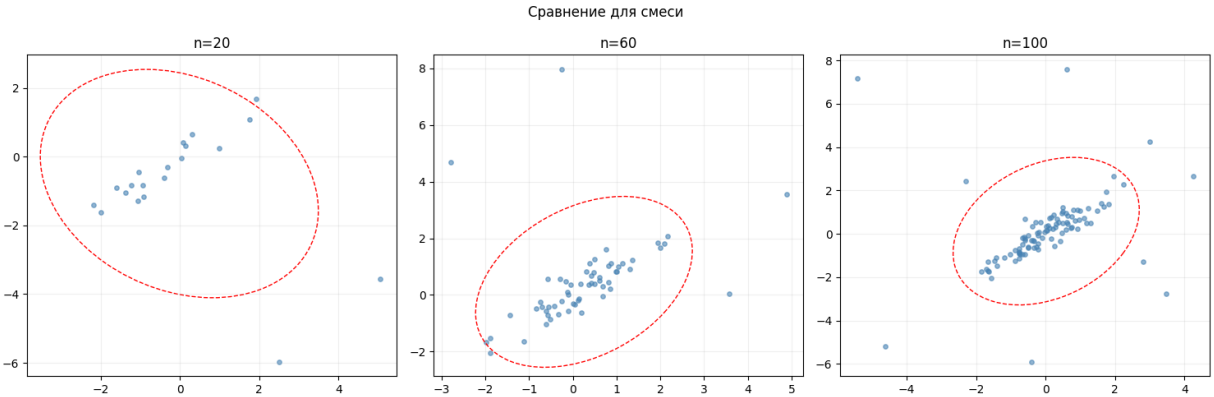

Рис. 5: Диаграммы рассеиваний и эллипсы равновероятностей для смеси

5 Обсуждение

Из результатов вычислительных экспериментов видно, что коэффициенты корреляции Пирсона и Спирмена близки к теоретическим значениям ρ даже для выборок малого объема (Рис. 1). О коэффициенте квадрантной корреляции такое

сказать нельзя: он систематически дает заниженную оценку силы связи. Однако в условиях «загрязненных» данных (модель *mixture*) именно квадрантная корреляция демонстрирует наиболее адекватные результаты, значительно превосходя классические методы в устойчивости.

Анализ графического материала (Рис. 2–4) подтверждает теоретические сведения: с ростом коэффициента корреляции эллипсы рассеивания сужаются, стремясь к прямой линии. При этом объем выборки n напрямую влияет на точность ориентации эллипса — с увеличением количества точек угол наклона главной оси эллипса быстрее стабилизируется и совпадает с углом, соответствующим истинной линейной зависимости.

Для выборок со смесью распределений (Рис. 5) эллипсы практически полностью теряют свою информативность, несмотря на то, что доля выбросов в эксперименте составила всего 10%. В ходе текущего эксперимента для модели *mixture* были получены следующие значения углов наклона эллипсов (в радианах):

$$\alpha_{n=20} = 2.47, \quad \alpha_{n=60} = 1.04, \quad \alpha_{n=100} = 1.13$$

Такой разброс значений (особенно при $n = 20$) обусловлен тем, что при малых выборках мощные выбросы способны кардинально изменить направление главных компонент распределения.

6 Выводы

1. В отсутствие внешних помех ($\rho = 0, 0.5, 0.9$) коэффициенты Пирсона и Спирмена демонстрируют высокую точность и низкое смещение даже на малых выборках. Квадрантный коэффициент в этих же условиях дает стабильно заниженные оценки.

2. В случае «загрязненных» данных (*mixture*) квадрантный коэффициент корреляции проявляет свойства робастности: его значения искажаются значительно медленнее по сравнению с коэффициентами Пирсона и Спирмена.

3. Визуальный анализ подтвердил, что даже 10%-ное загрязнение выборки аномальными значениями (смесь $0.9N + 0.1N$) приводит к сильной деформации эллипсов равновероятности, что делает невозможным точное визуальное определение характера зависимости в таких данных.

7 Список литературы

1. Документация `scipy` - https://docs.scipy.org/doc/scipy/

2. Документация `seaborn` - https://seaborn.pydata.org/

8 Приложение

https://github.com/chumarena/MatStat/tree/main/Lab5